

Databázy a vizualizácia

SQL – Indexy v databázach

doc. Ing. Ladislav Körösi, PhD.

Ústav robotiky a kybernetiky
FEI STU Bratislava

SQL - INDEXY

Prečo potrebujeme indexy

Predstavme si tabuľku s veľkým množstvom záznamov.

Chceme nájsť konkrétny riadok podľa hodnoty stĺpca.

```
SELECT * FROM auta  
WHERE nazov = 'BMW';
```

Ak tabuľka nemá index, databáza musí postupne prehľadať všetky riadky tabuľky.

Tento spôsob sa nazýva **full table scan**.

Pri veľkých tabuľkách môže byť takýto dotaz veľmi pomalý.

Index v databáze funguje podobne ako register alebo index v knihe.

Ak chceme nájsť konkrétnu kapitolu v knihe, nemusíme čítať všetky strany. Pozrieme sa do obsahu, kde nájdeme číslo strany.

Podobne funguje aj databázový index.

- obsahuje hodnoty vybraného stĺpca,
- ku každej hodnote obsahuje odkaz na riadok tabuľky,
- databáza tak môže nájsť údaje rýchlejšie.

Index je teda pomocná dátová štruktúra, ktorá zrýchľuje vyhľadávanie v tabuľke.

Index dokáže výrazne zrýchliť vyhľadávanie údajov v tabuľke.

Databáza nemusí prehľadávať všetky riadky, ale použije index na rýchle nájdenie požadovaných údajov.

Index však nie je zadarmo.

- databáza musí index udržiavať,
- index zaberá dodatočný priestor na disku,
- operácie INSERT, UPDATE a DELETE môžu byť pomalšie.

Pri každej zmene údajov musí databáza aktualizovať aj príslušný index.

Index nie je len zoznam hodnôt. Je uložený pomocou špeciálnej dátovej štruktúry.

Väčšina databáz používa pre indexy **stromový štruktúru**.

Strom umožňuje rýchle vyhľadávanie hodnoty medzi veľkým množstvom údajov.

Namiesto prehľadania všetkých riadkov databáza postupne prechádza stromom a rýchlo nájde požadovanú hodnotu.

V databázach sa najčastejšie používa štruktúra **B-tree (resp. B+tree)**.

Index má zmysel vtedy, keď databáza potrebuje rýchlo vyhľadať konkrétne riadky.

Najčastejšie sa používa pri:

- podmienkach WHERE,
- spojení tabuliek (JOIN),
- triedení (ORDER BY),
- zoskupovaní (GROUP BY).

Ak sa stĺpec často používa v týchto operáciách, je vhodným kandidátom na index.

Index pomáha databáze nájsť potrebné údaje bez prehľadania celej tabuľky.

Index nie je vždy výhodný.

Nepomáha napríklad v prípadoch:

- malé tabuľky (rýchlejšie je prejsť všetky riadky),
- podmienky typu LIKE '%text',
- použitie funkcií nad stĺpcom,
- stĺpce s malým počtom rôznych hodnôt.

V takýchto prípadoch databáza často index nepoužije.

Index má najväčší prínos pri veľkých tabuľkách a selektívnych podmienkach.

SQL - INDEXY

Vytvorenie indexu

Index môžeme vytvoriť pomocou príkazu `CREATE INDEX`.

```
CREATE INDEX idx_nazov  
ON auta(nazov);
```

Tento index urýchli vyhľadávanie podľa stĺpca `nazov`.

Index môžeme aj odstrániť.

```
DROP INDEX idx_nazov  
ON auta;
```

Názov indexu si volíme sami.

V databázach existuje viacero typov indexov.

- **PRIMARY KEY**

- automaticky vytvára index,
- zabezpečuje jednoznačnosť.

- **UNIQUE**

- neumožňuje duplicitu,
- zároveň vytvára index.

- **INDEX**

- bežný index pre zrýchlenie vyhľadávania.

Indexy môžu obsahovať jeden alebo viac stĺpcov.

SQL - INDEXY

Zložený index (composite index)

Index môže byť vytvorený nad viacerými stĺpcami.

```
CREATE INDEX idx_auto_farba  
ON auta(nazov, farba_id);
```

Takýto index funguje efektívne pre:

- vyhľadávanie podľa nazov,
- vyhľadávanie podľa nazov a farba_id.

Menej efektívny je pre:

- vyhľadávanie len podľa farba_id.

Poradie stĺpcov v indexe je dôležité. Pri indexe (nazov, farba_id) je najprv zoradený podľa nazov a až potom podľa farba_id. To znamená, že databáza vie rýchlo nájsť všetky riadky pre konkrétny nazov. Ak hľadáme len podľa farba_id, databáza nevie preskočiť na správne miesto v indexe a musela by prechádzať veľkú časť indexu. Ak hľadáme len podľa farba_id, databáza nevie preskočiť na správne miesto v indexe musela by prechádzať veľkú časť indexu.

Pomocou príkazu EXPLAIN môžeme zistiť, ako databáza vykoná dotaz.

```
EXPLAIN  
SELECT *  
FROM auta  
WHERE nazov = 'BMW';
```

Databáza ukáže:

- či použije index,
- alebo vykoná full table scan.

Tento príkaz je užitočný pri optimalizácii dotazov.

Indexy tabuľky môžeme zobraziť pomocou príkazu:

```
SHOW INDEX FROM auta;
```

Výstup obsahuje napríklad:

- názov indexu,
- stĺpce indexu,
- typ indexu (BTREE, HASH),
- informáciu o unikátnosti.

Väčšina indexov v MySQL používa typ **BTREE**.

Index je uložený v stromovej štruktúre.

Vyhľadávanie prebieha postupne:

- od koreňa stromu,
- cez vnútorné uzly,
- až k listom.

Databáza tak nemusí prehľadávať všetky údaje.

Počet krokov rastie pomaly aj pri veľkom množstve dát.

Preto je vyhľadávanie pomocou indexu veľmi rýchle.

Niektoré databázy používajú aj **hash indexy**.

Hodnota stĺpca sa pomocou hash funkcie prepočíta na konkrétnu pozíciu.

Vyhľadávanie je veľmi rýchle:

- priamy prístup na základe vypočítanej hodnoty,
- bez prechádzania stromovej štruktúry.

Hash index má však obmedzenia:

- funguje len pre porovnanie rovnosti (=),
- nepodporuje rozsahy (<, >),
- nepoužíva sa pri triedení (ORDER BY).

Preto sa v praxi častejšie používajú B-tree indexy.

Index je veľmi dôležitý pri spájaní tabuliek.

Ak spájame tabuľky napr. pomocou `auta.farba_id = farby.id` je vhodné mať index:

- na `auta.farba_id`,
- na `farby.id` (často PRIMARY KEY).

Bez indexu musí databáza pri JOIN porovnávať veľké množstvo riadkov.

Indexy sú dôležitým nástrojom pre optimalizáciu databáz.

- zrýchľujú vyhľadávanie údajov,
- využívajú sa pri WHERE, JOIN, ORDER BY,
- majú aj svoju cenu pri zmene dát.

Index je vhodné vytvárať len tam, kde prináša reálny prínos.

Nesprávne použitie indexov môže výkon aj zhoršiť.